

Relatório de evolução do projeto — Sprint 03

EV Challenge GoodWe · Prompt and Artificial Intelligence · FIAP 2026.2 · GoodWe ChargeOps AI Assistant · modelo principal
gpt-oss:120b · gerado em 2026-09-20 23:05

1. Resumo da evolução

Nas Sprints 1 e 2 o chatbot era uma implementação manual: o agente montava à mão uma lista de mensagens com o system prompt, um bloco de contexto GoodWe e 11 few-shots (**3700 tokens fixos** reenviados em toda chamada), fazia `requests.post` no Ollama sem nenhum parâmetro de geração, guardava o histórico numa lista sem limite e deixava ao modelo tanto a aritmética de recarga quanto o respeito ao escopo.

Na Sprint 03 o núcleo conversacional foi reconstruído em LangChain LCEL, com as quatro peças do Módulo 1. A chain `ChatPromptTemplate` | `ChatOllama` | `StrOutputParser` usa o system prompt versionado. A memória por sessão combina `RunnableWithMessageHistory` e `ConversationTokenBufferMemory`, com teto de 1.200 tokens. O schema Pydantic v2 `ConsultaRecarga` tem `field_validator` para números no formato brasileiro e alimenta uma calculadora determinística. O context engineering usa XML tagging, medição com tiktoken e guardrails de entrada e saída. A arquitetura resultante segue abaixo.

moderação → validação de escopo → RunnableBranch → extração estruturada (Pydantic) → cálculo determinístico → [prompt | LLM | parser] com memória → validação de saída. O código legado em `ai/` não foi alterado: ele é o grupo de controle do comparativo.

2. Refatoração: decisões técnicas e trade-offs

Decisão	Detalhe e trade-off
O LLM extrai, o Python calcula	O modelo só preenche <code>ConsultaRecarga</code> ; tempo, energia e custo saem de <code>src/dominio/recarga.py</code> e entram no prompt como <code><calculo_verificado></code> . Eficiência AC de 89,4% (faixa 85,7–92,0%), de Sears, Roberts e Glitman (IEEE SusTech, 2014). Custo: uma chamada extra de LLM nos turnos numéricos, acionada por gatilho barato para não pagar em perguntas conceituais.
Guardrails determinísticos antes do LLM	Injeção, jailbreak, privilégio, fraude, domínio jurídico/financeiro/elétrico, produto fora da base e fora de escopo são resolvidos por regras auditáveis, com resposta fixa e encaminhamento a profissional. O prompt v2 é a segunda camada: spotlighting em <code><pergunta_usuario></code> e canário. Trade-off: regras não cobrem paráfrase infinita, por isso existe a defesa em profundidade.
Memória: janela de tokens + fatos estruturados	A classe exigida poda mensagens antigas. Para não esquecer dados críticos, os fatos já validados pelo Pydantic ficam em <code><fatos_da_sessao></code> , fora da janela. É a política de resumo adotada: estruturada, sem chamada extra e sem risco de o resumo alucinar número. Turnos bloqueados não entram na memória (evita envenenamento do histórico).
Régua única de tokens	tiktoken <code>o200k_harmony</code> , o tokenizador do próprio gpt-oss (antes: <code>cl100k_base</code> , aproximado). Tokens reais do servidor (<code>usage_metadata</code>) registrados à parte, pois incluem o raciocínio.
Compatibilidade LangChain 1.x	<code>ConversationTokenBufferMemory</code> e <code>RunnableWithMessageHistory</code> estão marcadas como deprecated em favor do LangGraph (Módulos 3/4). Mantidas porque o escopo as exige; um adaptador (<code>HistoricoComLimiteDeTokens</code>) faz uma funcionar dentro da outra sem reescrever a poda.

3. Tabela de comparativo antes/depois (mesmo eval set, 28 casos)

Métrica	Sprints 1/2 (manual/legado)	LCEL cru	Sprint 03 (LCEL) v1	Sprint 03 (LCEL) v2 — final
Qualidade: nota do juiz (0–2)	pendente	pendente	pendente	pendente
Qualidade: conformidade	pendente	pendente	pendente	pendente
Tokens por turno (o200k_harmony)	pendente	pendente	pendente	pendente
Tokens reais do servidor por turno	pendente	pendente	pendente	pendente
Latência média (ms)	pendente	pendente	pendente	pendente
Latência p90 (ms)	pendente	pendente	pendente	pendente
Acurácia do structured output (campos)	pendente	n/a	n/a	pendente
Structured output: schema válido	pendente	n/a	n/a	pendente
Turnos resolvidos sem LLM (guardrails)	pendente	pendente	pendente	pendente
Tokens fixos do system prompt	3700	~40	307	987
Guardrails: bloqueio / falso positivo	inexistente	inexistente	100,0% / 0,0%	100,0% / 0,0%

Método: um único runner e um único adaptador por coluna, mesmo eval set (v1.1), mesma régua de pontuação (v1.1) e mesmo juiz (*glm-5.3-flash*, fora dos modelos avaliados, temperatura 0). A coluna LCEL cru isola o efeito do framework sozinho; v1/v2 somam prompt, structured output e guardrails. O structured output do legado mede o caminho manual equivalente (LLMProvider do legado + json.loads, 15 casos com gabarito), porque a Sprint 2 não tinha saída estruturada. Guardrails medidos offline em 39 ataques/pedidos restritos e 44 perguntas legítimas; encaminhamento a profissional em 11/11 recusas de domínio restrito.

4. Problemas encontrados e soluções

Problema	Causa	Solução	Por quê
Falso verde de autenticação	GET /api/tags da ollama.com é público; o diagnóstico passava e o 401 só aparecia na chain.	Diagnóstico passou a validar com POST /api/chat (src/teste_auth.py).	Validar no endpoint que de fato exige a credencial.
Resposta vazia do modelo	gemma4/glm-flash devolvem vazio com o campo think; o gpt-oss esgotava num_predict=400 no raciocínio.	think só para famílias de raciocínio; num_predict 1024; with_fallbacks repete sem think e com o dobro do orçamento.	Vazio virava nota 0 por falha de transporte, não de qualidade.
Instrução de formato cara	get_format_instructions() gerava 1060 tokens por extração.	Instrução compacta gerada do mesmo schema (508 tokens); parse e validação seguem no PydanticOutputParser.	Mesma garantia, menos contexto.
Régua de pontuação com falso acerto	O termo "h" casava com qualquer texto; listas sem ponto contavam como 1 frase.	pontuacao.py v1.1: termo curto como palavra isolada, itens de lista contados; todas as colunas reexecutadas.	Mudar a régua exige remedir todos os lados.
Legado sem credencial de nuvem	O código de ai/ foi escrito para o Ollama local e não envia Authorization.	Adaptador troca só o transporte (proxy do requests e host/modelo da instância); nenhum arquivo de ai/ alterado.	Preservar o grupo de controle.
Falso positivo de escopo	"Traduz ... 'state of charge'" era bloqueado: o léxico do domínio não tinha termos em inglês.	Termos EN adicionados; conjunto de regressão com 44 perguntas legítimas.	Bloquear demais também é defeito e é medido.

5. Equipe e divisão de trabalho

Nome	RM	Tarefa principal
Davi Q. Zuolo	571669	PREENCHER
Gustavo Zagato	569420	PREENCHER
Daniel Vilela Mana	571632	PREENCHER
Kayo Henderson	570706	PREENCHER

Reprodução: `pip install -r requirements-sprint3.txt`, configurar `.env` a partir de `.env.example`, `python -m evals.executar_tudo`. Todos os números deste relatório são rastreáveis até os JSONs em `evals/resultados/` e o consolidado `evals/sprint3_results.json`.